

# 王峰

✉ fengwang@stu.pku.edu.cn · 📞 15112645887 · 🗣️ wfswechatid · 🌐 caseclose



## 🎓 教育背景

🏛️ 北京大学

2024.09 – 2027.06

硕士研究生在读 信息工程学院 计算机科学与技术

研究方向：多模态 Agent、强化学习、多模态理解、Code 驱动数据合成

🏛️ 哈尔滨工业大学

2020.09 – 2024.06

学士 计算学部 / 英才荣誉学院 信息安全 专业排名：2/82 雅思: 6.5 CET6: 530

## ⚙️ 实习经历

腾讯-微信 (WXG) 技术架构部

科研实习 2025.11 – 2026.08

### 一、认知结构化多模态 Agent (CMA)

📄 论文 🌐 项目主页 📁 代码

架构已落地微信小微 Agent 链路，灰度测试中

- **问题重构**：多轮多模态对话面临视觉 token 随轮次线性膨胀、无关图像相互干扰、长历史推理不稳定三重瓶颈。洞察到**文本历史是连续的而视觉历史是稀疏的**——每轮实际只需少量历史图像，据此将任务重构为**视觉上下文选择问题**：学习策略从历史中选出最小相关图像子集，把“全量重放视觉上下文”改为“检索式访问”。由感知抽象引擎 (PAE) 压缩感知输入为情景视觉记忆 (EVM)、认知检索引擎 (CoRE) 做轮级检索、多模态执行控制器 (MEC) 统一调度工具调用与任务执行。
- **数据与训练**：自建 Unified Scenario Engine 程序化合成带细粒度检索标注的 20 轮长对话，绕开长时序检索监督的人工标注瓶颈；设计 CoRE SFT→CoRE RL→PAE RL 三阶段训练 (8 节点分布式)，CoRE 以难度加权 Jaccard 为奖励，PAE 则冻结 CoRE、直接以下游检索准确率为奖励实现下游对齐，而非 caption 质量一类代理指标。
- **效果**：构建 M2CA-Bench (100 会话/2,000 标注轮次，中英双语、按时间跨度与指代歧义等四维度分级、严格 hold-out)；**PAE+CoRE 使 32B 基线 Full 81.9%→92.0%、Hard 62.0%→83.5%，单轮延迟 23.1s→12.7s、生成质量 7.93→8.77**；8B 模型亦达 Full 91.4%、Hard 82.0%，中文 Full 89.6%。
- **消融与对比**：三阶段训练在 Hard 子集上逐级贡献 63.6%→70.9%→77.4%→82.0%；相较 MemoryLLM/ReasoningBank 式纯文本记忆在 Hard 上仅 24.4%/39.0%，本方案达 82.0%，验证缩略图与文本元数据并存的必要性；对比并发 Agent 框架 GenArtist，长对话后半程生成质量仅衰减 0.45 (9.51→9.06)，而其衰减 1.97。
- **工程落地与 C 端闭环**：交付 CMA-Harness (17 个工具、多作用域持久化记忆、OpenAI 兼容 API)，设计只读工具异步扇出、写工具串行的读写分离并发模型，配合“零 LLM 启发式 → 文本预筛 → 多模态检索”三级降级控制调用成本。架构已迁移至微信小微 Agent 链路并进入灰度测试，持续基于真实用户反馈数据做 badcase 归因与迭代优化。

### 二、InfoCodeGen：Code 驱动的信息图生成

面向 WeGen Omni V4 基座模型，CoT 写码即生成、渲染器即标注器

- **推理管线**：打通 CoT 中生成 HTML/SVG/受限 LaTeX、再经渲染器出图的信息图生成链路——模型在思维链里规划版式与文案并写出可执行源码，由排版引擎确定性渲染，把“像素级生图”改为“推理写码 + 渲染执行”。
- **问题与思路**：信息图文字需同时满足字形正确、版式合理、风格多样与密度可控；GlyphControl/TextDiffuser/AnyText 等把文字当像素生成的路线在长文本与复杂版式下难以兼顾，且监督依赖 OCR 回标。提出**范式反转：不生成文字像素，而生成能渲染出文字的源码**，训练与推理共用同一中间表示。

- **数据合成**：同一套源码经 Playwright 确定性渲染为 PNG，bbox 从 DOM 的 `Range.getClientRects()` 直接读出，免除 OCR 回标；样本可按 `style_spec` 与随机种子完整重放。对源码做受控局部修改即产出编辑对（目标区域外像素改变率 <0.1%）。风格拆为 9 个正交控制轴（37 版式骨架 ×5 画布 ×4 档密度），字体按语言 coverage 门控；DOM 质检 → VLM 视觉复核 → 像素一致性三道质量门。
- **产出**：覆盖 6 种语言、5 种画布与 4 档密度的带 bbox 样本与双重校验编辑三元组，标注不依赖 OCR、可按需扩产，作为 WeGen Omni V4 基座模型的信息图训练数据，并反哺上述推理管线。

### 三、WeGen Omni V3 统一理解生成基座模型

垂域数据 & benchmark 建设（科学图 / 信息图 / 电商图），能力已落地「微试穿」与腾讯游戏，9 月初开源并发布技术报告

- **数据生产**：为 WeGen Omni V3 统一理解生成基座主导科学图、信息图、电商图三类垂域预训练 + SFT 数据建设，设计“规则粗筛-VLM 精筛-OCR/Caption 一致性校验-质量评测-迭代 refine”端到端 pipeline，从 3,200 万 + 原始图中产出约 490 万高质量训练数据。
- **评测体系**：建设文字渲染专项评测集（1,000 条真值，覆盖 10 类场景 ×5 档文本长度 ×4 档难度），以 OCR 与多模态读图两条独立链路交叉验证——前者区分多写与漏写，后者补充可辨性与阅读顺序诊断；刻意不加权合成官方总分，避免最宽松的指标决定整批结论，并按场景/长度/难度切片归因反哺数据构成与 caption 规则。
- **电商专项**：不按自有数据的自然频次采样，而以京东、淘宝电商大盘 SKU 分布为依据做长尾覆盖均衡，区分“缺数量”与“缺难例”定向补足；针对商品身份不可篡改的硬约束，以  $\Delta E(\text{CIEDE2000})$  配色漂移、logo 检测与特征匹配、OCR 编辑距离等标准逐维度构建商品一致性检测。进一步构建 53 万条覆盖 14 类任务的编辑指令支撑 556 万样本 SFT。
- **业务落地与开源**：模型能力已应用于微信电商试衣小程序「微试穿」与腾讯游戏业务；9 月初开源模型并发布技术报告。

### 百度-视觉技术部 (VIS) 多模态感知与理解组

科研实习 2025.04 – 2025.09

- **问题与思路**：GUI Agent 需针对人工指令输出动作与坐标，现有多模态模型存在两类典型失败——面对模糊的 high-level 指令误解意图、面对高分辨率密集界面定位偏移。提出 H2L-G1 工具增强推理框架，以两个互补工具将高层意图理解与像素级坐标回归解耦。
- **High2Low 指令工具**：把粗糙的高层指令改写为含控件类型、参照物与所在区域的精确描述，从源头消解意图歧义。
- **Zoom-in 分辨率工具**：将高分辨率截图等分为 patch 网格，先推理判定目标所在区块，再对该区块局部放大回归相对坐标与动作（覆盖 click、scroll、文本输入等 5 类），规避整图直接回归导致的坐标偏移。
- **训练与效果**：基于 Qwen2.5-VL 以 cold-start+GRPO 训练 High2Low 模型，再经数据蒸馏将指令具体化能力合入 Grounding 模型；较 UI-R1-3B 基线，ScreenSpot 均分 83.3 提升至 90.6、ScreenSpot-Pro 均分 17.8 提升至 37.3 并取得 SOTA，其中细小 Icon/Widget 控件的增益最为显著。

## 论文与科研成果

### Cognitive-structured Multimodal Agent (CMA)

一作 AAAI 2027 在投

长时序多模态 Agent 的情景视觉记忆与检索式上下文架构（详见腾讯实习一）。 [论文](#) [项目主页](#) [代码](#)

### Modality-Balanced Decoupling Alignment for Video-Text Retrieval

一作 AAAI 2027 在投

- 针对文本-视频检索中模态信息容量不对称、视频表征强耦合导致的语义鸿沟，提出模态平衡解耦对齐 (MBDA)：以模态接近对齐模块拉近视频与文本嵌入，以正交解耦模块分离对齐信息与模态特有信息。
- 通过低秩分解与 DFT 分析验证分量正交性，对齐分量与模态特有分量的余弦相似度自 0.052 降至 0.0042；消融显示两模块分别将 MSR-VTT 基线 42.1% 提升至 49.2% 与 47.8%、组合后达 52.4%，并在 MSR-VTT/DiDeMo/MSVD/ActivityNet 取得 52.4%/53.1%/54.0%/49.6% 的 SOTA 检索性能。

### H2L-G1: Advancing GUI Grounding with High-to-Low Tools

一作

工具增强的 GUI 定位框架，High2Low 消解高层指令歧义、Zoom-in 做细粒度定位；ScreenSpot / ScreenSpot-Pro SOTA（详见百度实习）。

Semantic-Guided Generative Image Augmentation with Diffusion Models

AAAI 2024

- 提出语义引导的扩散增广方法 SGID，以图像标签与 caption 构建 prompt，引导 Stable Diffusion 在提升样本多样性的同时保持语义一致性。
- 在 7 个数据集、ResNet-50/ViT/CLIP-ViT 等 backbone 上系统评测，较最优增广基线分别提升 1.72%、0.33% 与 0.14%，**ResNet-50 从零训练设定下提升达 10.39%**；进一步验证与 RandAugment 组合及 beam search、nucleus sampling、CLIP 筛选策略。

🔧 技术栈

---

- 后训练**：大规模 SFT、GRPO / DAPO 强化学习、cold-start + RL、能力蒸馏；奖励设计与下游任务对齐（Agent 检索策略、GUI Grounding）
- 多模态理解与 Agent**：VLM（Qwen3-VL / Qwen2.5-VL）的数据建设、训练、评测与部署；多模态 Agent 工具调用与记忆检索；亦覆盖统一基座（WeGen Omni / BAGEL）与图像编辑模型（Qwen-Image / Qwen-Image-Edit）
- 训练与推理基建**：千卡规模基座模型训练、多节点分布式训练（ms-swift）、vLLM 张量并行与多端点批量推理、CFG 双卡并行加速
- Code 驱动生成**：以源码为中间表示的生成范式——CoT 写 HTML/CSS/SVG/受限 LaTeX、排版引擎确定性渲染出图；以语法约束解码保证源码合法，渲染即校验——失败带报错回流重写
- 数据工程**：Playwright 无头渲染合成、DOM 级 bbox 直读（免 OCR 回标）、style\_spec 与随机种子可复现重放、千万级图文数据管线、OCR/VLM 自动质检与切片归因
- 语言与框架**：Python / PyTorch、C / C++、HTML / CSS / SVG、LaTeX、FastAPI、Gradio、OpenAI 兼容 API

🔧 项目竞赛经历

---

全国大学生数学建模竞赛国家二等奖: FAST 主动反射面的优化调节

项目组长2021.09

美国大学生数学建模竞赛 Honorable Mention: 自行车赛中最优功率分配的研究

2022.03

全国大学生数学竞赛（非数学类）二等奖

2021.12

传输、存储、认证安全的全栈加密银行

独立完成2022.10 – 2022.11

基于 JavaWeb 独立开发全栈虚拟支付系统，以 SET 协议、对称/非对称加密、电子信封与双重签名保障传输、存储与身份认证安全，对接实现电子商务平台的安全支付。

♡ 其他情况

---

- 奖学金: 光华奖学金 (3/556), 腾讯奖学金 (8/556), 一等人民奖学金 (3%), 英才奖学金
- 参与 GitHub 开源项目: Top-AI-Conferences-Paper-with-Code，目前项目已经获得 2.6k stars
- 学生工作: 曾任哈工大英才荣誉学院科创中心主席，班长